

Proyecto Final - Data Scientist (DS)

Tripletten

Instrucciones específicas para la etapa 2: Código de solución

1. Propósito

En esta etapa deberás implementar el proceso definido en tu plan de trabajo de tal forma que construyas un modelo predictivo utilizable en el contexto del caso, mediante el debido manejo de tus datos y la aplicación de criterios de experimentación y evaluación técnica.

En este sentido, deberás demostrar tus capacidades de brindar soluciones a problemas reales a partir de un enfoque basado en datos, en el cual desarrolles paso a paso dicha solución, desde los datos originales hasta un modelo reproducible y de alta confiabilidad.

2. Contenido esperado del entregable

Para que tu entregable sea aprobado, el mismo deberá ser realizado en Jupyter Notebook y contener al menos lo siguiente:

1. **Procesamiento y limpieza de datos:** Se espera que seas capaz de:
 - Identificar y ajustar los tipos de datos correspondientes con la naturaleza de cada variable.
 - Identificar y dar tratamiento a valores duplicados, perdidos o inconsistencias lógicas derivadas del contexto del caso.
 - Dado que contarás con distintas fuentes de información, deberás vincular las variables relevantes en un solo dataset mediante procesos de concatenación y/o unión.
 - Crear o modificar variables que te aseguren contar con atributos confiables y completos, y una variable objetivo claramente definida.
2. **Preparación de datos para modelamiento:** La generalidad de algoritmos de aprendizaje computacional requieren que los datos de los que aprenden cumplan con ciertos criterios técnicos mínimos. Entonces, tu deberás asegurar esto ejecutando las siguientes actividades:

- Codificar atributos no numéricos de tal manera que sean comprensibles por los algoritmos que utilices.
 - Particionar los datos considerando la potencial naturaleza temporal de los mismos y de forma que sea factible una debida evaluación técnica.
 - Escalar o transformar variables de tal forma que se eviten sesgos por un mal dimensionamiento de los datos y/o las magnitudes.
 - Balancear las clases en caso que exista una distribución no uniforme de los casos observados en la variable objetivo.
3. **Modelamiento:** Utilizando los datos limpios y preparados, deberás ahora iniciar con el entrenamiento de los algoritmos que hayas definido en tu plan de trabajo. Con este propósito es importante que incluyas lo siguiente:
- Un modelo básico cuyos resultados de rendimiento en cuanto a los KPIs establecidos en tu plan de trabajo, sirvan como referencia mínima de calidad. En este punto es recomendable la utilización de algoritmos básicos como pueden ser los clasificadores o regresores *dummy*, según sea el caso.
 - Construcción, entrenamiento y validación técnica de los diferentes algoritmos definidos en el plan de trabajo y contrastar su rendimiento en cuanto a los KPIs con el modelo base.
 - Calibración de umbrales y ajuste de hiperparámetros como mecanismo para mejorar los resultados alcanzados.
 - Determinación de la importancia relativa de los atributos en el pronóstico alcanzado del mejor modelo creado.
4. **Resumen de resultados:** Describe finalmente las principales conclusiones alcanzadas. Recuerda que una buena conclusión no es una descripción de los resultados sino una interpretación de los mismos en el contexto del caso. En esta etapa igualmente podrías incluir las limitaciones encontradas en cuanto a los datos y los modelos implementados.

3. Aspectos negativos a evitar en el entregable

Un entregable adecuado debería evitar lo siguiente:

- Enfoque exclusivo en aspectos técnicos sin una aclaración respecto a su relación o impacto en el contexto del caso.
- Copiado literal de código generado por IA sin una debida comprensión de tu parte.
- Código que genere errores o interrupciones inesperadas en la ejecución.
- Falta de celdas markdown que den un mayor contexto y profundidad al código.
- Código que no tenga ninguna relación con la solución o que aporte poco o nada al proceso de limpieza, preparación y modelamiento planificado.
- Modelos sobreajustados

Vale señalar que si tu entregable presenta alguna de estas características, es probable que el revisor no lo apruebe y debas modificarlo.

4. Recomendaciones específicas

- En primer lugar, conviene que sigas este orden general para resolver el caso:
 1. Si bien puedes empezar a probar algunos aspectos de tu plan de trabajo previo a que este sea aprobado por el revisor, no es conveniente iniciar con la parte de modelamiento en este punto.
 2. En este sentido, inicia tu documento final de este entregable una vez que tu plan de trabajo haya sido aprobado.
 3. Una vez que lo hayas concluido tu documento, envíalo para revisión.
 4. Si recibes observaciones por parte del revisor, has los ajustes necesarios en tu documento y reenvíalo.
 5. Una vez aprobado, continua con la siguiente etapa (Código de solución).
- En vista que tu código debe ser reproducible, te sugerimos que utilices raíces aleatorias tanto en las actividades de preparación y modelamiento.
- Adicionalmente, te sugerimos que de forma preferente descargues todos los archivos necesarios desde la plataforma de TripleTen a fin de que puedas desarrollar todo tu trabajo localmente.
- Vinculado a lo anterior, asegúrate de mantener todos los archivos organizados en directorios fáciles de acceder en tu computadora, y has respaldos frecuentes de los documentos más sensibles.

4. Sigue con esto:

Una vez que tienes claro lo descrito en este documento, continua con los siguientes documentos de instrucciones específicas.

3. Instrucciones para la etapa 3: Informe de solución