

Proyecto Final - Data Scientist (DS)

Tripletten

Instrucciones específicas para la etapa 1: Plan de trabajo

1. Propósito

Antes de empezar cualquier proyecto real de análisis de datos, es importante planificar las actividades a desarrollar. Por lo tanto, en esta etapa se busca que desarrolles un documento claro, lógico y detallado con todos los pasos que te permitan resolver el problema expuesto, mediante el correcto entendimiento del contexto del caso y de los datos que se proporcionan en el mismo.

En este sentido, es recomendable que investigues un poco sobre el sector donde opera la empresa del caso, y hagas un diagnóstico inicial de los datos que te han sido entregados aplicando técnicas de estadística descriptiva.

2. Contenido esperado del entregable

Para que tu entregable sea aprobado, el mismo deberá contener al menos lo siguiente:

1. **Identificación del problema de negocio:** Indica de forma concreta qué se necesita hacer en el proyecto desde la perspectiva del negocio, y explica por qué realizarlo brindará valor. Para esto, es recomendable que por tu cuenta investigues acerca del sector en el que opera la empresa del caso.
2. **Descripción de los datos:** Realiza una descripción de los datos con los que trabajarás; en concreto, deberás indicar al menos lo siguiente:
 - El detalle del volumen de tus datos (número de filas y columnas).
 - El nivel de calidad de los datos (existencia de valores perdidos, duplicados, tipos de variables incorrectos, etc.).
 - Un resumen estadístico de las variables existentes (estadísticos de centralidad, dispersión y posición, distribuciones, tablas de frecuencias, etc.).

- Cuáles son las variables de mayor interés en el contexto del caso, especificando cuál sería el objetivo de pronóstico de los modelos que construyas, y cuáles serían los mejores atributos a emplear.

3. **Hipótesis de modelamiento:** Plantea y justifica cuáles serían los mejores algoritmos a utilizar de acuerdo a tu criterio, y que permitan dar solución al problema de negocio expuesto. Recuerda que más que la cantidad de algoritmos que plantees, interesa que los mismos sean capaces de pronosticar adecuadamente la variable objetivo, ante lo cual es recomendable que cumplan con los siguientes requisitos:

- Deben pertenecer al tipo correspondiente en cuanto a la necesidad de clasificar, agrupar o hacer regresión.
- Debes ser capaz de implementarlos con los datos disponibles.
- Se deben cumplir los supuestos básicos en cuanto a atributos y variable objetivo.
- Deben ser verificables utilizando criterios rigurosos y robustos de validación técnica.

Vale señalar que deberás especificar al menos 3 algoritmos distintos, pudiendo estos ser los vistos en el curso u otros que investigues por tu propia cuenta.

4. **Indicadores clave (KPIs):** Define claramente los indicadores que vas a utilizar para comprobar la validez de los algoritmos que implementes. Si ves conveniente, incluso puedes describir estos KPIs a modo de fórmulas matemáticas. Junto con cada uno de los indicadores, recuerda establecer cuáles serían los umbrales aceptables que deberían alcanzar los resultados del modelamiento, y que satisficerían los criterios esperables en el contexto del caso.

5. **Diseño experimental:** Especifica las estrategias que utilizarás en cada uno de los algoritmos para mejorar los resultados. Recuerda incluir métodos como validación cruzada, ajuste de hiperparámetros, balanceo de variables, entre otros. Da una breve explicación de cómo estas estrategias serán útiles para alcanzar los umbrales definidos en cada uno de los KPIs.

6. **Acciones a ejecutar:** Describe una lista las tareas que vas a realizar a fin de ejecutar los modelamientos y por consiguiente dar solución al problema planteado. Es recomendable que este plan incluya de manera ordenada lo siguiente:

- Al menos tres actividades vinculadas al procesamiento y limpieza de los datos.
- Al menos tres actividades vinculadas a la preparación de datos para los distintos algoritmos (i.e codificación, escalamiento, transformación, particionamiento, etc.).
- Actividades vinculadas al desarrollo de modelos, incluyendo la creación de modelos base, y modelos optimizados mediante las estrategias del diseño experimental definidas.
- Al menos dos actividades vinculadas a la comunicación de resultados (visualizaciones, informe final, etc.)

- Tiempos estimados para cada una de las actividades. Recuerda que para **TODO** el proyecto final cuentas con dos semanas, por lo que estos tiempos deberían ajustarse a esta limitante.

7. **Stakeholders impactados:** Menciona a qué roles o áreas del negocio dentro de la empresa le serán de interés los resultados alcanzados, y explica por qué seleccionaste estos stakeholders.

3. Aspectos negativos a evitar en el entregable

Un entregable adecuado debería evitar lo siguiente:

- Copiado literal del enunciado del contexto del caso sin una reformulación que evidencie tu entendimiento del negocio y los datos.
- Formulación de hipótesis de modelamiento genéricas, ajenas al problema de negocio o inalcanzables con las herramientas o datos disponibles.
- Enlistado de actividades y tareas genéricas que no estén acorde al problema de negocio y los datos.
- No referenciar variables objetivo y atributos.
- Enfoque exclusivo en aspectos técnicos sin una aclaración respecto a su relación o impacto en el contexto del caso.
- Copiado literal de código generado por IA sin una debida comprensión de tu parte.
- Código que genere errores o interrupciones inesperadas en la ejecución.
- Falta de celdas markdown que den un mayor contexto y profundidad al código.

Vale señalar que si tu entregable presenta alguna de estas características, es probable que el revisor no lo apruebe y debas modificarlo.

4. Recomendaciones específicas

- En primer lugar, conviene que sigas este orden general para resolver el caso:
 1. Lee con detenimiento el contexto del caso y consulta con tu tutor si tienes alguna duda.
 2. Investiga sobre el sector donde opera la empresa y has un breve diagnóstico de los datos.
 3. Desarrolla el entregable en Jupyter Notebook incluyendo todo lo solicitado y envíalo para revisión.
 4. Mientras esperas la aprobación de tu entregable, estudia a profundidad sobre los algoritmos que planteaste y la forma adecuada de implementarlos.

5. Si recibes observaciones por parte del revisor, has los ajustes necesarios en tu documento y reenvíalo.
 6. Una vez aprobado, continua con la siguiente etapa (Código de solución).
- Adicionalmente, te sugerimos que de forma preferente descargues todos los archivos necesarios desde la plataforma de TripleTen a fin de que puedas desarrollar todo tu trabajo localmente.
 - Vinculado a lo anterior, asegúrate de mantener todos los archivos organizados en directorios fáciles de acceder en tu computadora, y has respaldos frecuentes de los documentos más sensibles.

4. Sigue con esto:

Una vez que tienes claro lo descrito en este documento, continua con los siguientes documentos de instrucciones específicas.

2. Instrucciones para la etapa 2: Código de solución
3. Instrucciones para la etapa 3: Informe de solución